

А. В. Вагнер, et al.(?)

# Разработка систем Искусственного Интеллекта в здравоохранении

Книга 1. Машинное обучение



Алматы  
2027



**Александр Вагнер, кандидат технических наук**, специалист в области Биостатистики, Методов оптимизации, Data Science & AI. С 1974 года занимается разработкой: Автоматизированных Систем Управления (АСУ), Автоматизированных информационных и информационно-поисковых систем, Автоматизированных систем научных исследований, Систем искусственного интеллекта.

Научные и проектные интересы: Прикладная математическая статистика, Методы оптимизации, управление большими объемами данных (Big Data), Text-minning, анализ данных и моделирование (Система здравоохранения, клинические исследования, рыночные и фармацевтические исследования, страхование и банки), Business Intelligence (BI); Хранилища данных (DW) и банки данных (DB); Оптимизация ИТ процессов; Data Science & AI

Отрасли внедрения: Здравоохранения и медицина, Фармориндустрия, Банки, Страховые компании, Нефтеснабжение, Издательство, полиграфия и книжная торговля, Оборонные Ведомства, Санитарно-эпидемиологическая служба, Наука и научное обслуживание.

Места трудовой деятельности: Вычислительные Центры, Проектные и Научно-Исследовательские Институты, Научные Центры, Международные Фармо-компании (Merck, Pfizer, Daiichi Sankyo), CRO, Производители медоборудования (BIOTRONIK, ACANDIS), Страховые компании (ARAG), Доцент Университетов (Математические Методы Оптимизации, Математическая Статистика, Программирование)

**Автор 2**

Образование:



**Автор 3**

Образование:



## Предисловие

Уважаемые читатели, предлагаемая вашему вниманию монография посвящена теме создания Систем Искусственного Интеллекта (СИИ) в здравоохранения и смежных отраслях, таких как: медицинское страхование, фармация, анализ результатов клинических исследований и др. Она может быть полезна всем интересующимся проблемами создания систем ИИ.

Авторы посвятили теме создания Автоматизированных информационно-аналитических систем многие десятилетия активной работы в различных организациях связанных с этой проблемой как в Казахстане, так и за рубежом, в том числе в: подразделениях практического здравоохранения, Всемирной Организации Здравоохранения в роли представителя Казахстана, специализированных НИИ и Научных Центрах, Министерстве здравоохранения Казахстана и его подразделениях в роле руководителей высшего звена и организаторов здравоохранения, организациях медицинского страхования, предприятиях Фармоиндустрии, в Мединститутах в роли руководителей и преподавателей, специализированных ИТ фирмах и организациях. Всё это позволило авторам обобщить многолетний опыт создания Аналитических Интеллектуальных информационных систем, включая системы Искусственного Интеллекта. В настоящей работе использованы собственные разработки, внедренные в практику в Казахстане и за рубежом и опубликованные в специализированных журналах. Авторы использовали в данной работе многочисленные источники информации, опубликованные в открытом доступе как физическими лицами, так и специализированными фирмами-разработчиками, все источники приведены в списке литературы и при необходимости приведены веб-ссылки в тексте. Авторы настоящего произведения не несут ответственности за содержание и выводы изложенные в использованных материалах.

## Ведение

Создание современных Автоматизированных информационных интеллектуальных систем анализа и прогноза данных и ситуаций в различных сферах науки, техники, социальной сфере, в том числе здравоохранении, основанных на методах продвинутой статистики(Advanced statistics) и Искусственного Интеллекта (Artificial intelligence), является очень сложной и трудоемкой задачей. Во всём мире тратятся на эту работу триллионы долларов ежегодно, в этой работе задействовано миллионы высокквалифицированных и высокооплачиваемых сотрудников.

В республике Казахстан со времён обретения независимости возникла задача создания собственных интеллектуальных систем в Здравоохранении, разработанных своими научно-производственными кадрами. Это очень непростая задача, связанная с высокими материальными затратами, требующая большого количества высокквалифицированных специалистов в различных сферах науки и техники, таких как:

- Медицина
- Математика и статистика
- Информатика
- Наука о данных (Data Science)
- Искусственный Интеллект (Artificial intelligence)
- Медицинское страхование
- Другие области деятельности

Авторы видят свою задачу в передаче (транспорте) знаний, приобретенных за многие годы работы в области разработке таких систем специалистам, работающим в этой сфере. Основываясь на своем опыте разработки интеллектуальных систем в разных

странах и фирмах, связанных с системой здравоохранения, они систематизировали этот опыт и представляют его всем заинтересованным читателям в виде данной работы.

Авторы назвали свою работу «Разработка систем Искусственного Интеллекта в здравоохранении», далее «Разработка СИИ». Это практическое руководство направлено широкому кругу специалистов занимающихся проблемой создания Автоматизированных Интеллектуальных Систем в здравоохранении. Авторы сознательно не усложняют материал изложенный в пособии сложными математическими выкладками и излагают его максимально понятным для студентов медфакультетов (и других специальностей) языком.

Практическое руководство состоит из двух книг:

Книга 1. Машинное обучение

Книга 2. Глубокое обучение

### ***Цель написания данной книги***

Целью создания данной монографии является:

- Обеспечение студентов и магистрантов медицинских факультетов университетов, сотрудников и научных и административных работников, работающих в системе здравоохранения информацией о современных методах анализа медицинской информации и прогноза сценариев развития ситуаций, системой Искусственного Интеллекта «HealthAI» для применения методов ИИ в научно-практической и административной работе
- Повышение уровня и качества управления отраслью здравоохранения за счет внедрения передовых Информационных технологий и методов анализа и прогноза данных и параметров о состоянии управляемого объекта, таких как здоровье населения, обеспечение его медицинской помощью, медикаментами и т.п.
- Обучение методам разработки и применения оптимальных моделей управления ресурсами и определения тенденций развития в отрасли здравоохранения
- Повышения качества подготовки медицинских кадров и их конкурентоспособности на рынке труда

### ***Назначение монографии***

Данная монография предназначена для студентов и магистрантов медицинских факультетов университетов, сотрудников, научных и административных работников, работающих в системе здравоохранения, руководящих работников и специалистов, занятых анализом информации, прогнозом и выработкой стратегических направлений совершенствования управления и оптимизации отрасли здравоохранения, всем интересующимся вопросами разработки систем ИИ на примерах, изложенных в данном пособии. Практическое руководство может быть использована как справочник или руководство по созданию систем ИИ в здравоохранении.

### ***Структура книги 1 монографии***

Книга 1 монографии состоит из 11 глав, объединенных общей темой Аналитические информационные системы в здравоохранении созданные с помощью методов продвинутой статистики, Искусственного Интеллекта и Web-технологий

Главы организованы следующим образом:

Глава 1. Искусственный Интеллект. Основные определения и базовые понятия

Глава 2. Моделирование в среде Машинного Обучения. Основные определения, компоненты и процедуры

Глава 3. Краткое описание моделей машинного обучения используемых в системе «HealthAI»

Глава 4. Многоядерная многофункциональная интегрированная Web-Computig Эко-система «Применение методов Искусственного Интеллекта в Медицине, Здравоохранении и смежных областях «HealthAI»

Глава 5. Программно-техническое обеспечение Web-базируемых систем Искусственного Интеллекта

Глава 6. Работа с локальными и удаленными репозиториями систем Искусственного Интеллекта, размещение систем на Web-сервере

Глава 7. Аналитическая Информационная Система «АИС ВТИИ»

Глава 8. Автоматизированная система научных исследований в медицине, здравоохранении и смежных областях «АСНИ-МЕД»

Глава 9. Web-базируемая «Обучающая Система» на основе методов Искусственного Интеллекта

Глава 10. Система Искусственного Интеллекта Фонда социального медицинского страхования «ИИ-ФСМС»

Глава 11. Выводы на основании опыта разработки WEB-базируемых систем Искусственного Интеллекта в Здравоохранении и перспективы дальнейшего развития Системы Искусственного Интеллекта «HealthAI»

Список литературы

Приложение

Материал монографии изложен на 300 страницах и включает текст, 12 таблиц, 187 графиков, список литературы из 200 наименований.

## **Система Искусственного Интеллекта «HealthAI»**

Описанные в данной работе научно-технические определения, термины, алгоритмы, математические модели, языки программирования, базы данных и технологии использованы в практике создания системы Искусственного Интеллекта «HealthAI», состоящей из 4-х subsystem, каждая из которых функционально независима и работает в Cloud-Computing режиме. Система «HealthAI» и её компоненты подробно описана в главах 7-10 данной работы. Система была неоднократно доложена в виде докладов на международных конференциях (SAS-Konferenz, Wiesbaden-2023), Asfendijarov FORUM-2023/2025, Almaty, специальных заседаний кафедры Менеджмент в Здравоохранении Asfendiyarov University, демонстрировалась коллегам других Университетов и НИИ Алматы, часть материалов опубликованы в специализированных научных журналах и переданы на регистрацию в Агенстве Интеллектуальной Собственности РК.

## **Глава 1. Искусственный Интеллект. Основные определение и базовые понятия**

### **Базовые определения, используемые в системах Искусственного Интеллекта**

В Оксфордском словаре (Lexico, 2019) ИИ определяется как «теория и развитие компьютерных систем, которые могут выполнять задачи, обычно требующие человеческого интеллекта, такие как визуальное восприятие, распознавание речи, принятие решений, а также перевод и интерпретация».

[1] [https://www.lexico.com/en/definition/artificial\\_intelligence](https://www.lexico.com/en/definition/artificial_intelligence)

Для основных определений мы, не вдаваясь в строгие теоретические дефиниции и философские рассуждения, используем статью по адресу

[2] <https://evergreens.com.ua/ru/articles/machine-learning-overview.html>.

**Искусственный интеллект (Artificial intelligence, AI)** – это различные технологические и научные решения и методы, которые помогают сделать программы по подобию интеллекта человека. Artificial intelligence включает в себя множество инструментов, алгоритмов и систем, среди которых также все составляющие Data science и Machine learning. Схематично Artificial intelligence можно представить в виде рис. 1.




Рис. 1. Структура Искусственного Интеллекта

## Глава 2. Моделирование в среде Машинного Обучения. Основные определения, компоненты и процедуры

### 1. Основные определения и сведения о машинном обучении

Данная глава посвящена проблемам моделирования в сфере Машинного Обучения (МО). С определением понятие МО, можно ознакомиться в статье, размещенной под ссылкой: <https://www.lyzr.ai/glossaries/machine-learning/>

**Машинное обучение(МО) или Machine learning** – это один из разделов AI, алгоритмы, позволяющие компьютеру делать выводы на основании данных, не следуя жестко заданным правилам. То есть, машина может найти закономерность в сложных и многопараметрических задачах (которые мозг человека не в состоянии решить), таким образом находя более точные ответы. Как результат – верное прогнозирование.

(МО) — это подмножество искусственного интеллекта (ИИ)

Wiki:

[https://ru.wikipedia.org/wiki/%D0%9C%D0%B0%D1%88%D0%B8%D0%BD%D0%BD%D0%BE%D0%B5\\_%D0%BE%D0%B1%D1%83%D1%87%D0%B5%D0%BD%D0%B8%D0%B5](https://ru.wikipedia.org/wiki/%D0%9C%D0%B0%D1%88%D0%B8%D0%BD%D0%BD%D0%BE%D0%B5_%D0%BE%D0%B1%D1%83%D1%87%D0%B5%D0%BD%D0%B8%D0%B5)

Машинное обучение позволяет системам учиться на данных, выявлять закономерности и принимать решения или прогнозы с минимальным вмешательством человека. Используя передовые алгоритмы МО, машины могут со временем повышать свою производительность, улучшая обучение ИИ и предоставляя мощные решения для принятия решений на основе данных.

Машинное обучение лежит в основе прогнозного моделирования и автоматизированной аналитики, преобразуя отрасли, позволяя создавать инновационные приложения в различных областях, таких как финансы, здравоохранение, маркетинг и т. д.

#### **Определение машинного обучения в простых терминах**

Машинное обучение - это тип искусственного интеллекта, который фокусируется на том, чтобы помочь компьютерам научиться выполнять задачи, на которые они не были запрограммированы. Подобно тому, как люди учатся на опыте, компьютеры с машинным обучением собирают идеи из выполнения задач и анализа данных и применяют то, что они научились, для решения новых задач.

#### **Разница между ИИ и ML**

Искусственный интеллект (ИИ) – это широкая область, которая относится к способности машины выполнять задачи, которые обычно требуют человеческого интеллекта. Машинное обучение (ML) – это подполе искусственного интеллекта, которое конкретно относится к машинам, которые могут выполнять задачи, требующие человеческого интеллекта, не будучи явно запрограммированными на это.

#### **Формирование будущего с помощью машинного обучения**

Машинное обучение находится на переднем крае технологических инноваций, позволяя интеллектуальным системам обучаться, адаптироваться и трансформировать отрасли человеческой деятельности. Используя методы машинного обучения, компании могут использовать большие объемы данных со скрытой в них информации для принятия более разумных решений и предоставления превосходного пользовательского опыта.

Для специалистов по обработке данных, разработчиков искусственного интеллекта и инженеров машинного обучения овладение машинным обучением имеет решающее значение, чтобы оставаться конкурентоспособными в быстро меняющейся среде искусственного интеллекта.

### **Глава 3. Краткое описание моделей машинного обучения используемых в системе «HealthAI»**

В данной главе кратко изложены сведения об основных моделях МО, которые используются в системе «HealthAI» в том числе:

- Random Forest
- Модель Decision Tree A
- Модель Decision Tree B
- Модель XGBoosting A
- Модель XGBoosting B
- Модель Gradient Boosting A


- Модель Gradient Boosting B
- Модель K-Nearest Neighbor (KNN)
- Модель Ada Boost

### **Модель Random Forest. Краткое определение и пояснение алгоритма**

Случайный лес или случайный лес решений — это контролируемый алгоритм машинного обучения, используемый для классификации, регрессии и других задач с использованием деревьев решений. Случайные леса особенно хорошо подходят для обработки больших и сложных наборов данных, работы с многомерными пространствами признаков и предоставления одерживать высокую точность прогнозирования при минимизации переобучения делает его популярным выбором в различных областях, включая финансы, здравоохранение и анализ изображений, среди прочих.

#### **Random Forest Classifier**

Классификатор случайного леса создает набор деревьев решений из случайно выбранного подмножества обучающего набора. Это набор деревьев решений (DT) из случайно выбранного подмножества обучающего набора, а затем он собирает голоса из разных деревьев решений, чтобы принять окончательное предсказание.



**Рис 2. Схема Random Forest классификатора**

Кроме того, классификатор случайного леса может решать как задачи классификации, так и регрессии, а его способность предоставлять оценки важности признаков делает его ценным инструментом для понимания значимости различных переменных в наборе данных.

Как работает классификация случайного леса

## **Глава 4. Многоядерная многофункциональная интегрированная Web-Computig Эко-система «Применение методов Искусственного Интеллекта в Медицине, Здравоохранении и смежных областях «HealthAI»**

В данной главе излагаются основные положения системы «HealthAI», в том числе: архитектура, функциональная структура, состав и описание специального программного обеспечения, краткое описание информационной базы, режим функционирования в Web-пространстве, последовательность действий по размещению системы на cloud-сервере и описание технологии работы пользователей с системой.

### ***Сфера деятельности системы «HealthAI»***

Сферой деятельности системы является:

- Здравоохранении в целом
- Медицина
- Медицинское страховании
- Научные исследования в области Медицины
- Подготовка медицинских кадров высшей и средней квалификации
- Фарминдустрия
- Другие области, связанные с охраной здоровья населения

### ***Цель создание системы «HealthAI»***

Главная цель создание системы заключается в упрощении и облегчении процесса анализа медико-социальных данных и построение моделей прогноза ситуаций в процессах, происходящих в медицине, здравоохранении и в смежных областях (в медицинском страховании, в фарминдустрии и т.п.)

Цель реализуется через предоставление следующих возможностей пользователю:

- Простой и беспроблемный доступа к Базе статистических знаний
- Запуск типовых программ Анализа данных без необходимости инсталляции специальных статистических систем на пользовательском компьютере
- Самостоятельное решение своих (научных) проблем по Анализу медицинских данных
- Предоставление других услуг

### ***Назначение системы***

Система предназначена для широкого круга пользователя, в том числе:

- Студентов медицинских факультетов
- Аспирантов и докторантов медицинских факультетов
- Научных работников сферы здравоохранения
- Администраторов здравоохранения
- Сотрудников специализированных организаций, занимающихся анализом данных клинических исследований (Clinical Trials, <https://en.wikipedia.org/wiki/ClinicalTrials.gov>).
- Других пользователей

### ***Область применения системы***

Данная Система предусмотрена для использования в обучающем процессе и на всех уровнях управления. Это означает, что как на государственном (с расширенным функциональным набором), так и на областных/территориальных уровнях система работает идентично. Привилегированный пользователь может использовать без ограничения все данные и возможности системы.

Другие пользователи имеют доступ только к данным конкретной области. Система построена по модульному принципу и является открытой для развития и расширения.

### ***Задачи решаемые при помощи системы***

При помощи «HealthAI» решаются следующие задачи:

- Визуальный анализ данных при помощи интерактивных графиков и таблиц различного типа и свойства, отображающих в динамическом режиме, например, состояние основных показателей здоровья населения территории
- Составление аналитических отчетов о состоянии параметров и показателей управляемого объекта, например, здоровья населения территории

- Научный анализ данных и прогноз при помощи современных средств продвинутой статистики (Advanced Statistics) и методов Искусственного Интеллекта
- Построения моделей оптимизации работы отрасли или организации
- Другие оперативные и стратегические задачи

Методы решения задач «HealthAI»

Для решения поставленных задач АИС используются методы:

- Агрегации данных и создания многомерных отчетов
- Визуализации данных (динамические графики, карты, пр.)
- Классической прикладной математической статистики
- Методы статистического моделирования, в том числе Монте Карло
- Методы Доказательной медицины (Evidence Based Medicine)
- Методы Экономической медицины (Health Economics)
- Методы Искусственного Интеллекта, в том числе: Машинного обучения (Machine learning), глубокого обучения (Deep learning)
- Математические Методы оптимизации (Operations Research)
- Эвристические методы

### ***Результаты применения системы***

Результатами являются:

- Отчеты научно-исследовательских работ
- Статьи и презентации на научно-практических конференциях
- Диссертационные работы
- Отчеты плановых и коммерческих проектных работ
- Другие формы выходных результатов научных и проектных работ

### ***Экономический эффект от внедрения «МЕД-ИИ» состоит:***

- В сокращении времени на обработку данных, повышение качества выходных результатов и минимизации неоптимальных затрат на ИТ
- В сокращение стоимости затрат на компьютерную технику, так как система расположена в Веб-пространстве
- В дополнительной прибыли от применения оптимальных решений, сокращающие непроизводительные расходы
- В дополнительной прибыли от обучения слушателей курса «Школа разработчика Data Science»

### ***Научно-технический эффект состоит в:***

- Использование современных Информационных технологий и программного обеспечения, соответствующего развитию науки и мировой практики в создании аналогичных систем
- Принятие оптимальных решений ранее невозможных

### ***Социальный эффект от внедрения «МЕД-ИИ» состоит:***

- В подготовка кадров на курсах повышения квалификации «Школа разработчика Data Science» для руководящего состава, специалистов и всех заинтересованных лиц в онлайн и оффлайн режимах. Это позволит, в том числе, ликвидировать дефицит специалистов и решить проблему занятости молодежи в стране.

### ***Эко-пространство «Web-MedAI» для системы «HealthAI»***

В данном подразделе приводится краткое описание Эко-пространство для WEB базированных систем Искусственного Интеллекта и режима их работы.

Под Эко- пространством мы понимаем среду существования и жизнедеятельности систем, созданных на базе методов Искусственного Интеллекта, как совокупности

программных, технических, информационных, технологических, организационных и др. компонентов объекта интеллектуального продукта специального вида.

Эко- пространство «WEB ИИ» это многоядерная, распределенная, WEB-базируемая среда (обитания) в социо-техническом универсуме «Разработчик приложений-WEB Платформа-Пользователь приложений» или в общепринятых терминах «App developer -WEB Platform-App User».

Авторами предложена технология разработки и использования WEB базированных систем Искусственного Интеллекта (WEB ИИ). Эта технология позволяет осуществлять разработку и эксплуатацию/использование таких систем в непрерывном цикле, без деления отдельных этапов этого цикла на изолированные фазы. В целом такой подход позволяет:

- Стандартизировать и унифицировать процесс разработки и эксплуатации WEB ИИ
- Обеспечить разработку и пользователя эффективным инструментом управления процессом создания и эксплуатацию WEB ИИ систем
- Снизить сроки создания WEB ИИ систем
- Сэкономить людские и материальные ресурсы на создании WEB ИИ систем



Рис. 3. Функциональные компоненты (подсистемы) Эко-системы «HealthAI», состояние на сентябрь 2026 г.

Это предложение является ноу-хау авторов данной технологии в процессе разработки и эксплуатации WEB ИИ. Авторы данного учебного пособия надеются, что специалистов WEB ИИ и заказчиков таких систем заинтересует это решение.

### **Функциональная структура эко-системы «HealthAI»**

Функциональная структура Эко-системы «HealthAI» состоит в настоящий момент из нескольких подсистем Искусственного Интеллекта, в том числе:

- Автоматизированная Web-базируемая система научных исследований в медицине, здравоохранении и смежных областях «АСНИ-МЕД»
- Web-базируемая Обучающая система Искусственного Интеллекта
- Аналитическая Web-базируемая Информационная Система «АИС ВТИИ»

- Web-базированная Система Искусственного Интеллекта Фонда социального медицинского страхования «ИИ-ФСМС»
- Система Искусственного Интеллекта Фонда социального медицинского страхования «ИИ-Диагностика»
- Диагнозы

Количество подсистем в будущем будет возрастать. Каждая подсистема может состоять из одной или более субсистем 2-го уровня, расширяющих возможности члена триады и решающая специальные задачи.

### Среда программирования эко-системы «HealthAI»

В качестве программирования систем Искусственного Интеллекта нами избрана платформа ANACONDA с её средствами (описание приведено в гл. 5).

### GUI системы «HealthAI»

#### Назначение GUI

- Autoit-GUI предназначена для управления процессом эксплуатации Экосистемы «HealthAI» и выполняет следующие функции:
- Запускает Подсистемы Экосистемы «HealthAI»
- Осуществляет визуализацию Рутон скриптов в окне Autoit-GUI
- Осуществляет визуализацию документа «Концепт Системы» в окне Autoit-GUI
- Осуществляет визуализацию характеристик файлов GitHub Repository (Content) в специальном формате (Json, HTML) в окне Autoit-GUI
- Осуществляет выбор файлов из окна и запускает функции:
  - Download (перемещение набора данных из GitHub Repository в локальный Repository)
  - Upload (перемещение набора данных из локально Repository в GitHub Repository)
  - PushData (обновление набора данных в GitHub Repository)




Рис. 4. GUI для Эко-системы «HealthAI»

### Краткая описание программы GUI для Эко-системы «HealthAI»

Программа GUI разработана с помощью Autoit

Структура и краткое описание программы

Программа создания GUI состоит из множества собственно разработанных UDF(User Defined Fuction). Ниже приведены некоторые важные для понимания работы программы UDF или программные блоки.

Программная оболочка (GUI) Web-приложения «HealthAI» значительно упрощает администратору и пользователям системы работу с ней. Администратор имеет возможность значительно сократить временные издержки по обновлению (Update) системы.

При клике на кнопку «WEB APP-Report» GUI, открывается Web-приложение в окне GUI Пользователь имеет возможность выполнять различные манипуляции с данными, хранящимися как на локальном диске компьютера так и в GitHub, в том числе:

- Перенос отчётов, данных, графических объектов, программ и прочего как с локального диска в GitHub (Upload), так и обратно (Download)
- Просматривать отчёты и другую информацию на страницы субсистем (ядер)
- Запускать программы субсистем (ядер) «HealthAI»
- Просматривать руководства по эксплуатации субсистем (ядер) «HealthAI»
- Просматривать историю создания субсистем (ядер) «HealthAI»
- Просматривать информации о разработчиках субсистем (ядер) «HealthAI»
- Просматривать литературные источники по тематике разработки субсистем (ядер) «HealthAI» и другим вопросам ИИ, для этого достаточно нажать на соответствующий линк на странице «Источники»
- Выполнять другие действия

Программная оболочка (GUI) прошла длительные испытания при эксплуатации различных систем, как общего назначения в Client-Server «Business Intelligence (BI)», так и в Web-приложениях Искусственного Интеллекта и показала свою устойчивость при эксплуатации и эффективность в практическом применении

## **Глава 5. Программно-техническое обеспечение Web-базируемых систем Искусственного Интеллекта**

В данной главе изложены базовые материалы по практическому созданию систем Искусственного Интеллекта, в том числе:

- Программного обеспечения
- Среда программирования ANACONDA
- Язык программирования Python
- IDE (Интегрированная среда разработки), Программный редактор Jupyter Notebook
- Другие программно-технические и справочные материалы

В качестве программирования систем Искусственного Интеллекта нами избрана платформа ANACONDA (в среде Windows) с её средствами.

### **Важные инструменты, которые используются в области Data Science**

#### ***Инструменты Data Science***

1. Anaconda
2. Язык программирования Python
3. IDEs: Jupyter Notebook

Как область, наука о данных движется с другой скоростью, чем многие другие области. Машинное обучение постоянно развивается и библиотеки продолжают совершенствоваться. Исследовательские компании, такие как Open AI и Deep Mind, продолжают раздвигать границы того, что может делать машинное обучение. По сути,

навыки, необходимые для того, чтобы быть специалистом по данным, остаются прежними: статистика, программирование Python/R, знания SQL или NoSQL, и визуализация данных. Однако инструменты, которые используют ученые, постоянно меняются.

## ***Среда программирования ANACONDA***

### **Зачем использовать Anaconda?**

Anaconda - это менеджер пакетов и дистрибутивов для Python, который позволяет легко управлять библиотеками и инструментами, необходимыми для вашего проекта по науке о данных. Это также позволяет создавать виртуальные среды, что позволяет работать над несколькими проектами, требующими разных версий Python или библиотек без риска конфликтов. (В будущей статье мы увидим, как создать виртуальные среды для организации и изоляции различных проектов в области науки о данных, над которыми вы работаете.)

Anaconda - это широкое распространение языков программирования Python и R для научных вычислений (наука о данных, приложения машинного обучения, крупномасштабная обработка данных, предиктивная аналитика и т. Д.). Он направлен на упрощение управления пакетами и развертывания. Система управления пакетами conda управляет версиями пакетов.

Некоторые ключевые особенности Anaconda включают в себя:

1. **Обширные пакеты:** Anaconda имеет большую коллекцию предустановленных научных вычислительных и информационных пакетов, экономя время и усилия в создании сред.
2. **Conda Package Manager :** Anaconda использует Conda, менеджер пакетов, который упрощает установку, запуск и обновление пакетов и их зависимости.
3. **Environment Management** Anaconda позволяет создавать изолированные среды, чтобы избежать зависимостей и конфликтов между проектами.
4. **Кросс-платформа:** Работает в Windows, macOS и Linux.
5. **Открытый исходный код:** Anaconda является открытым исходным кодом, что позволяет неограниченное использование и распространение.
6. **Anaconda Navigator :** настольный графический пользовательский интерфейс (GUI), включенный в Anaconda, который позволяет запускать приложения и эффективно управлять пакетами конда, средами и каналами без использования команд командной строки.
7. **Поддержка ноутбука Jupyter:** Anaconda включает в себя Jupyter Notebook, мощный инструмент для интерактивного исследования и визуализации данных.
8. **Сообщество и коммерческие издания :** Anaconda предлагает как бесплатное, так и коммерческое издание с дополнительными функциями и поддержкой.

Anaconda особенно хорошо подходит для ученых, исследователей и всех, кто работает в области, которая требует обработки больших наборов данных, сложных вычислений или научных расчетов. Он широко используется в академических и коммерческих условиях для анализа данных, машинного обучения и научных вычислительных задач.

## ***Язык программирования Python: история, особенности, режимы исполнения и приложения***

Python является **языком программирования** и широко используется в качестве центра многих приложений в Data Science. Он был разработан **Гвидо Ван Россумом в 1989 году в Национальном научно-исследовательском институте, Нидерланды**, но был официально выпущен 20 февраля 1991 года. Ван думал, что ему нужно таинственное имя, поэтому не мог не назвать его Python из популярного телешоу под названием «The Complete Python's Circus».

## Специальные программные средства Python для создания эко-системы «HealthAI»

Базовыми специальными программными средствами создания системы «HealthAI» являются в настоящий момент Streamlit и Plotly Dash. Ниже приводится краткое описание базовых специальных программных средств.

### *Streamlit*

[Streamlit](#) получил значительную поддержку среди ученых данных за его способность быстро преобразовывать сценарии данных в интерактивные веб-приложения с минимальным кодированием. Он идеально подходит для прототипирования, создания приборных панелей и демонстрации идей данных. Тем не менее, он менее подходит для приложений, требующих сложных пользовательских интерфейсов или постоянной интерактивности.

#### **Плюсы**

- **Быстрое прототипирование:** Streamlit превосходит быстрое преобразование сценариев Python в веб-приложения с минимальными усилиями.
- **Визуализация данных:** Streamlit имеет встроенные компоненты для общих задач визуализации данных, что делает его идеальным для приборных панелей.
- **Простота использования:** декларативный синтаксис Streamlit позволяет разработчикам сосредоточиться на функциональности, а не на коде шаблона.
- **Примеры, управляемые сообществом:** Streamlit имеет надежную галерею приложений с примерами и шаблонами на таких платформах, как Github, демонстрируя, как создавать различные приложения Streamlit и панели инструментов.

#### **Минусы**

- **Execution Inefficiency:** Streamlit повторно запускает весь код приложения при каждом входном изменении, что приводит к потенциальной неэффективности. Это делает его менее подходящим для приложений со сложными рабочими процессами или крупномасштабными данными, которые требуют частых обновлений.
- **Ограниченные компоненты пользовательского интерфейса:** по сравнению с такими фреймворками, как Reflex или React, Streamlit предлагает ограниченный набор элементов пользовательского интерфейса, что делает его менее подходящим для создания сложных пользовательских интерфейсов.
- **Scalability Масштабируемость:** Streamlit не предназначен для создания долгосрочных или высокоинтерактивных приложений со сложными рабочими процессами.
- **Управление состоянием** приложения может стать сложным для более сложных приложений, требующих динамического взаимодействия с пользователем.
- **Кэширование:** Streamlit обеспечивает кэширование для повышения производительности, но кэширование крупных объектов может создавать проблемы, такие как высокое потребление памяти, медленная производительность или возврат устаревших данных. Кроме того, если кэш-лимация не обрабатывается должным образом, это может привести к непредсказуемому поведению, что затрудняет реализацию эффективных стратегий кэширования.

### *Plotly Dash*

Dash является наиболее загружаемой, надежной структурой для создания веб-приложений ML & Data science

Приложения для данных и панели инструментов для Python

[Dash](#) - это Python фреймворк для создания интерактивных аналитических веб-приложений. Он построен поверх Flask, Plotly.js и React.js, предлагая надежную среду для создания приборных панелей и приложений для передачи данных. Приложения Dash структурированы на два основных компонента: **макет**, который определяет визуальную

структуру с использованием компонентов HTML и React, и **обратные вызовы**, которые обрабатывают интерактивность, динамически реагируя на пользовательские входы.

Dash оптимизирован для эффективности развертывания, так как каждый компонент приложения является независимым, что позволяет легко перемещать горизонтальные масштабы. Тем не менее, это связано с компромиссом с требованием обратных звонков без гражданства, где каждый компонент должен быть независимым и автономным, что делает разработку более сложной для тех, кто привык к местному или государственному программированию.

#### **Плюсы**

- **Богатые компоненты данных:** Dash включает в себя обширную библиотеку предварительно встроенной визуализации данных и компонентов пользовательского интерфейса, что делает его идеальным для аналитических приложений.
- **Многоязычная поддержка:** Dash поддерживает Python, R и Julia, обслуживая широкую аудиторию в научном и информационном сообществах.
- **Академическая поддержка:** как одна из самых ранних фреймворков для визуализации данных на основе Python, Dash имеет сильное академическое сообщество.
- **Учебная интеграция:** Dash использует Plotly.js для создания настраиваемых и интерактивных визуализаций.
- **Deployment efficiency:** архитектура Dash позволяет легко масштабировать приложения по горизонтали, что делает его пригодным для развертывания в распределенных средах.

#### **Минусы**

- **Сложность обратного звонка:** управление интерактивностью с обратными вызовами может усложняться в больших или сложных приложениях. Каждый компонент должен работать независимо, не полагаясь на глобальные переменные или сохраненные промежуточные состояния, что может увеличить сложность развития.
- **Облачное развертывание:** хостинг Plotly в первую очередь ориентирован на корпоративных пользователей, и, хотя развертывание контейнеров возможно, это добавляет дополнительную сложность для отдельных разработчиков или небольших команд.

Каждая структура имеет свои сильные стороны и ограничения. Понимая, что каждый из них делает лучше всего, вы можете выбрать структуру, которая соответствует вашим целям проекта и делает разработку более плавной и эффективной.

## **Глава 6. Работа с локальными и удаленными репозиториями систем Искусственного Интеллекта, размещение систем на Web-сервере**

В данной главе изложены дополнительные базовые материалы по практической работе с локальными и удаленными репозиториями систем Искусственного Интеллекта (СИС), в том числе:

- Размещение проекта СИС на GitHub
- Размещение (Deploying) СИС на Web-сервере
- Компиляция Python - скрипта и создания выполняемого exe-файла для избранных subsystem
- Другие программно-технические и справочные материалы

### ***Система Git и хранилище GitHub***

В мире разработки программного обеспечения системы управления версиями стали важным инструментом для:

- управления и отслеживания изменений в коде

- сотрудничества с членами команды и поддержания четкой истории разработки проектов

## **Глава 7. Аналитическая Информационная Система «АИС ВТИИ»**

### ***Цель создания «АИС ВТИИ»***

Целью создания «АИС ВТИИ» является повышение уровня и качества управления в организациях и ведомствах, частных фирмах за счет внедрения передовых Информационных технологий и методов анализа и прогноза данных и параметров о состоянии управляемого объекта, например, здоровья населения, разработки оптимальных моделей управления ресурсами и определения тенденций развития отрасли или организации.

### ***Назначение «АИС ВТИИ»***

Система «АИС ВТИИ» предназначена для руководящих работников и специалистов, занятых анализом информации, прогнозом и выработкой стратегических направлений совершенствования управления и оптимизации отрасли и/или организации

### ***Задачи, решаемые «АИС ВТИИ»***

При помощи «АИС ВТИИ» решаются следующие задачи:

- Визуальный анализ данных при помощи интерактивных графиков и таблиц различного типа и свойства, отображающих в динамическом режиме например, состояние основных показателей здоровья населения территории
- Составление аналитических отчетов о состоянии параметров и показателей управляемого объекта, территории
- Научный анализ данных и прогноз при помощи современных средств продвинутой статистики (Advanced Statistics) и методов Искусственного Интеллекта
- Построения моделей оптимизации работы отрасли или организации
- Другие оперативные и стратегические задачи

### ***Область применения «АИС ВТИИ»***

Данная Система разработана для использования на всех уровнях управления. Это означает, что как на государственном (с расширенным функциональным набором), так и на областных/территориальных уровнях система работает идентично. Привелигированный пользователь может использовать без ограничения все функциональные возможности и данные системы. Другие пользователи имеют доступ только к данным конкретной области. Система построена по модульному принципу и является открытой для развития и расширения.

### ***Методы решения задач «АИС ВТИИ»***

Для решения поставленных задач АИС используются методы:

- Агрегации данных и создания многомерных отчетов
- Визуализации данных (динамические графики, карты, пр.)
- Классической прикладной математической статистики
- Методы статистического моделирования, в том числе Монте Карло
- Методы Искусственного Интеллекта, в том числе: Машинного обучения(Machine learning), в перспективе глубокого обучения(Deep learning)
- Математические Методы оптимитзации (Operations Research)
- Эвристические методы

***В процессе создания системы были определены сроки исполнения проекта и план работы первом этапе разработки системы***

- Был согласован концепт «АИС ВТИИ», временные и стоимостные характеристики её создания, соответственно внедрения
- Были определены и согласованы первоочередные задачи
- Были определены и согласованы технические характеристики и объемы Базы данных
- Были созданы, работающие в локальном, соответственно серверном варианте системы
- Были определены и согласованы режимы работы заказчика и исполнителя, в том числе:
  - Регулярные онлайн совещания
  - Обмен данными и результатами

***Организация работы***

Был создан рабочий коллектив из представителей заказчика и исполнителя из специалистов, обладающих необходимой научно-практической квалификацией и опытом создания и внедрения в практику аналогичных систем в стране заказчика и за рубежом

***Эффект от внедрения системы***

**Экономический эффект**

Экономический эффект от внедрения «АИС ВТИИ» состоит:

- В сокращении времени на обработку данных, повышение качества выходных результатов и минимизации неоптимальных затрат на ИТ
- В сокращении стоимости затрат на компьютерную технику, так как система расположена в Веб-пространстве и работает в режиме Cloud Computing
- В дополнительной прибыли от применения оптимальных решений, сокращающие непроизводительные расходы
- В дополнительной прибыли от обучения слушателей курса «Школа разработчика Data Science» (по возможности)
- Другие выгоды

**Научно-технический эффект**

- Использование современных Информационных технологий и программного обеспечения, соответствующего развитию науки и мировой практики в создании аналогичных систем
- Принятие оптимальных решений ранее невозможных

**Социальный эффект**

Подготовка кадров на курсах повышения квалификации «Школа разработчика Data Science» для руководящего состава, специалистов и всех заинтересованных лиц (платные) в онлайн и оффлайн режимах. Это позволит, в том числе, ликвидировать дефицит специалистов и решить проблему занятости молодежи.

**Имиджевый эффект**


Повышение авторитета организации-заказчика и страны за счет:

- Презентации «АИС ВТИИ» на международных конференциях
- Выпуск монографии по теме современных методов анализа и прогноза здоровья населения

- Кооперации с ведущими специализированными организациями (ВОЗ, Университеты, специализированные фирмы, занятые созданием интеллектуальных систем, например в здравоохранении)
- Научных публикаций в международных журналах и в Интернете
- Контакт с ведущими специалистами в данной области науки и техники

### **Функциональная структура «АИС ВТИИ»**

Функциональная структура «АИС ВТИИ» представляет собой совокупность программных модулей, организованных в последовательности исполнения согласно алгоритму, определённом в целях «АИС ВТИИ». Функциональная структура и взаимодействие программных модулей представлены на рис. 112.



**Рис. 5. Взаимодействие программных модулей в рамках функциональной структуры «АИС ВТИИ»**

Как видно из рис. 112, программные модули работают автономно и не связаны между собой. Это означает, что для создания и управления каждой отдельной страницы используется соответствующий модуль, который невозможно использовать в другой странице.

### **Описание системы «АИС ВТИИ»**

Система «АИС ВТИИ» состоит из 9 страниц (Tabs):

1. Титул-лист системы
2. Старт
3. Смертность населения в 2022г
4. Распределение населения по годам
5. Демография
6. Популяция
7. Возрастное распределение по странам
8. Прогноз заболеваемости
9. системе и авторе

Каждой странице соответствует программный блок, который будет описан ниже.

На следующих страницах приведены Screenы всех функциональных таблиц системы.




Рис. 6. Tab: Титульный лист системы «АИС ВТИИ»




Рис. 7. Tab: Старт системы



Рис. 8. Tab: Распределение населения по годам



Рис. 9. Tab: Демография



Рис. 10. Прогноз заболеваемости

## Глава 8. Автоматизированная система научных исследований в медицине, здравоохранении и смежных областях «АСНИ-МЕД»

### Цель создание системы

Главная цель создание системы заключается в упрощении и облегчении процесса анализа медико-социальных данных и построение моделей прогноза ситуаций в процессах, происходящих в медицине, здравоохранении и в смежных областях (в медицинском страховании, в фарминдустрии и т.п.)

Цель реализуется через предоставление следующих возможностей пользователю:

- Простой и беспрепятственный доступа к Базе статистических знаний
- Запуск типовых программ Анализа данных без необходимости инсталляции специальных статистических систем на пользовательском компьютере
- Самостоятельное решение своих (научных) проблем по Анализу медицинских данных
- Предоставление других услуг

### Назначение системы

Система предназначена для широкого круга пользователя, в том числе:

- Студентов медицинских факультетов
- Аспирантов и докторантов медицинских факультетов
- Научных работников сферы здравоохранения
- Администраторов здравоохранения
- Сотрудников специализированных организаций, занимающихся анализом данных клинических исследований (Clinical Trials, <https://en.wikipedia.org/wiki/ClinicalTrials.gov>)
- Других пользователей

### ***Область применения системы***

Данная Система предусмотрена для использования на всех уровнях управления. Это означает, что как на государственном (с расширенным функциональным набором), так и на областных/территориальных уровнях система работает идентично. Привилегированный пользователь может использовать без ограничения все данные и возможности системы.

Другие пользователи имеют доступ только к данным конкретной области. Система построена по модульному принципу и является открытой для развития и расширения.

### ***Задачи решаемые при помощи системы***

При помощи АСНИ решаются следующие задачи:

- Визуальный анализ данных при помощи интерактивных графиков и таблиц различного типа и свойства, отображающих в динамическом режиме, например, состояние основных показателей здоровья населения территории
- Составление аналитических отчетов о состоянии параметров и показателей управляемого объекта, например, здоровья населения территории
- Научный анализ данных и прогноз при помощи современных средств продвинутой статистики (Advanced Statistics) и методов Искусственного Интеллекта
- Построения моделей оптимизации работы отрасли или организации
- Другие оперативные и стратегические задачи

Методы решения задач АСНИ

Для решения поставленных задач АСНИ используются методы:

- Агрегации данных и создания многомерных отчетов
- Визуализации данных (динамические графики, карты, пр.)
- Классической прикладной математической статистики
- Методы статистического моделирования, в том числе Монте Карло
- Методы Доказательной медицины (Evidence Based Medicine)
- Методы Экономической медицины (Health Economics)
- Методы Искусственного Интеллекта, в том числе: Машинного обучения (Machine learning), глубокого обучения (Deep learning)
- Математические Методы оптимизации (Operations Research)
- Эвристические методы

### ***Результаты использования системы***

Результатами являются:

- Отчеты научно-исследовательских работ
- Статьи и презентации на научно-практических конференциях
- Диссертационные работы
- Отчеты плановых и коммерческих проектных работ
- Другие формы выходных результатов научных и проектных работ

### ***Краткое описание работы подсистемы «АСНИ-МЕД»***

Субсистема Web-App «АСНИ-МЕД» состоит в актуальной версии из 6 функциональных модулей разработанных при помощи Web Development Frameworks Dash. Субсистема запускается из управляющим и информативным GUI Web-базированной системы Искусственного Интеллекта «HealthAI» (см. Главу 4).

Титульная страница субсистемы состоит из боковика (Sidebar) в котором встроены 6 кнопок (Buttons). При помощи этих кнопок Web-App запускает определённый программный модуль, который производит последовательность действий и создаёт выходные объекты.



Рис. 11. Стартовая страница субсистемы

Например:

- Кнопка «**Введение в ASNI-MED**» запускает программу просмотра информации о «АСНИ-МЕД»
- Кнопка «**Разработчики системы**» запускает программу просмотра информации об авторах «АСНИ-МЕД»
- Кнопка «**Литература**» запускает программу просмотра списка литературы, используемой при разработке «АСНИ-МЕД»
- Кнопка «**Просмотр PDF-отчетов**» запускает программу просмотра PDF-отчетов, которые система создала в процессе работы
- Кнопка «**Старт проекта**» запускает программу инициации параметров Модуля «АСНИ-МЕД»
- Кнопка «**Старт программ избранных проектов**» запускает один из трех модулей «АСНИ-МЕД», в том числе: «EDA-Report», «ML-Report», «All-Report»

Примечание: Разработчики планируют значительно расширить функциональные возможности Web-App «АСНИ-МЕД»




Рис. 12. Страница: «Введение в ASNI-MED»




Рис. 13. Страница: «Старт программ избранного проекта», модуль: «EDA-Report»




Рис. 14. Страница: «Просмотр PDF-отчётов», модуль: «Моделирование и Анализ данных»

**Размещение (Deploy) «АСНИ-МЕД» Web-приложения на платформе Render**  
**Функциональная структура «АСНИ-МЕД» в виде блок-схемы**



Рис. 15. Блок-схема функционирования «АСНИ-МЕД»

## Глава 9. Web-базируемая «Обучающая Система» на основе методов Искусственного Интеллекта

### Предисловие

Одна из главных проблем при создании Автоматизированных интеллектуальных систем заключается в том, что их создание требует большого количества высококвалифицированных программистов. Их подготовка требует многих лет подготовки. Исследователь непрограммистов вынужден при анализе своих научных данных обращаться за помощью к профессиональным специалистам в области Анализа данных, в том числе:

- Математикам
- (Био) Статистикам
- Data Scientist (am)
- Другим специалистам

Здесь возникают проблемы времени выполнения анализа и стоимости услуг этих специалистов и не в последнюю очередь (удачной) находки такого специалиста.

При всё более усложняющихся проектах анализа, требующих всё более сложных моделей для анализа данных, которыми заказчик Анализа должен как минимум знать.

Исходя из этой ситуации возникает вопрос создания систем автоматизации научных исследований, этой теме посвящена глава 5 в этой книги. В предлагаемой

субсистеме нами предлагается вариант интерактивного анализа данных с практически не требуемыми знаниями в области программирования.

### ***Цель создание системы***

Основная цель создание системы заключается в упрощении и облегчении процесса анализа медико-социальных данных и построение моделей прогноза ситуаций в процессах, происходящих в медицине, здравоохранении и в смежных областях (в медицинском страховании, в фарминдустрии и т.п.)

Цель реализуется через предоставление следующих возможностей пользователю:

- Простой и беспроблемный доступа к Базе статистических знаний, стандартным алгоритмам аналитических программ
- Запуск типовых программ Анализа данных без необходимости инсталляции специальных статистических систем на пользовательском компьютере и программирования задач обработки данных
- Самостоятельное решение своих (научных) проблем по Анализу медицинских данных
- Предоставление других услуг

### ***Назначение системы***

Система предназначена для широкого круга пользователя, в том числе:

- Студентов медицинских факультетов
- Аспирантов и докторантов медицинских факультетов
- Научных работников сферы здравоохранения
- Администраторов здравоохранения
- Сотрудников специализированных организаций, занимающихся анализом данных клинических исследований (Clinical Trials, <https://en.wikipedia.org/wiki/ClinicalTrials.gov>)
- Других пользователей

### ***Область применения системы***

Данная Система предусмотрена для использования на всех уровнях обучения. Привилегированный пользователь может использовать без ограничения все данные и возможности системы.

Другие пользователи имеют доступ только к данным конкретной области. Система построена по модульному принципу и является открытой для развития и расширения.

### ***Задачи решаемые при помощи системы***

При помощи субсистемы решаются следующие задачи:

- Визуальный анализ данных при помощи интерактивных графиков и таблиц различного типа и свойства, отображающих в динамическом режиме, например, состояние основных показателей здоровья населения территории
- Составление аналитических отчетов о состоянии параметров и показателей управляемого объекта, например, здоровья населения территории
- Научный анализ данных и прогноз при помощи современных средств продвинутой статистики (Advanced Statistics) и методов Искусственного Интеллекта
- Построения моделей оптимизации работы отрасли или организации
- Другие оперативные и стратегические задачи

Методы решения задач АСНИ

Для решения поставленных задач АСНИ используются методы:

- Агрегации данных и создания многомерных отчетов
- Визуализации данных (динамические графики, карты, пр.)

- Классической прикладной математической статистики
- Методы статистического моделирования, в том числе Монте Карло
- Методы Доказательной медицины (Evidence Based Medicine)
- Методы Экономической медицины (Health Economics)
- Методы Искусственного Интеллекта, в том числе: Машинного обучения (Machine learning), глубокого обучения (Deep learning)
- Математические Методы оптимизации (Operations Research)
- Эвристические методы

### **Результаты использования подсистемы**

Подсистема используется для создания аналитических результатов, которые найдут применение в:

- Отчетах о научно-исследовательских работ
- Статьях и презентациях на научно-практических конференциях
- Диссертационных работах
- Отчетах плановых и коммерческих проектных работ
- Других формах выходных результатов научных и проектных работ

В разделе «Описание структура системы и режим её работы» приведено описание системы с точки зрения пользователя.



Рис. 16. Страница подсистемы, модуль: модуль: «EDA-Report, продолжение №1»





Рис. 17. Страница субсистемы, модуль: модуль: «EDA-Report, продолжение №3»




Рис. 18. Страница подсистемы, модуль: модуль: «ML-Report»




Рис. 19. Страница подсистемы, модуль: модуль: «ML-Report, продолжение №1»

**Примечание.** Обучающая Система при работе в режиме «ML-Report» для проведения анализа на реальных данных использовала 18 моделей Машинного обучения и сгенерировала табличные и графические объекты за 1:12 минут общего времени.

## **Глава 10. Система Искусственного Интеллекта Фонда социального медицинского страхования «ИИ-ФСМС»**

### ***Предисловие***

Система «ИИ-ФСМС» предназначена для специалистов Фонда социального медицинского страхования (ФСМС) по обработке/анализу данных и Data Science, чтобы помочь им в освоении применении технологии машинного обучения для улучшения качества анализа данных и построения достоверных прогнозов. Эта система была разработана по заказу руководства Фонда в ноябре-декабре 2024 года и потом переработана авторами в автономную Систему Искусственного Интеллектами интерактивного типа.

Материал данной главы посвящен научному исследованию в области медицинского страхования и созданию научного отчета по результатам моделирования средствами Машинного Обучения в среде Python. Описание научного исследования, выполнено по действующим международным стандартам, приводится в последующих разделах данного документа.

Data Science (Наука о данных) использует алгоритмы машинного обучения, которые позволяют извлекать ценные идеи и закономерности из огромных объемов данных. Для специалиста по данным важно иметь четкое представление о различных алгоритмах машинного обучения, чтобы эффективно выполнять сложные аналитические задачи. Ознакомившись с этими алгоритмами и их реализацией, сотрудники ФСМС смогут улучшить свои аналитические возможности и получить хорошие результаты в проектах, основанных на Науке о данных.

Data Science (Наука о данных) является прикладной наукой, а наука в целом - это наиболее сложная человеческая деятельность, для её успешного проведения требуются не только специальные личные качества, но и соответствующий инструментарий. Прежде всего — это исходные данные и средства их анализа. Во многих исследованиях этим инструментарием являются Статистика со всем набором современных методов анализа и прогноза данных и ситуаций и современные компьютерные системы, позволяющие это реализовать.

К сожалению, освоение этого научно-технического инструментария требует больших затрат времени и не всем желающим, это, в силу различных причин, удаётся. Эта проблема существует уже долгие годы и на протяжении длительного времени как крупные компании, так и небольшие организации испытывают постоянную потребность в квалифицированных Статистиках и Data Scientist(ax) (DS), к сожалению, их поиск и интеграция в структуру организации довольно сложная процедура и она не всегда завершается успехом.

### ***Цель данного исследования и пользователи «ИИ-ФСМС»***

Цель проекта «ИИ-ФСМС» на этапе предварительного Анализа данных средствами МО и построения прогноза ситуаций состоит в:

- В создание комплекса программных средств для автоматизированного анализа и прогноза данных ФСМС при помощи современных информационных технологий и методов Машинного обучения, соответственно и/или при необходимости других методов Искусственного Интеллекта.
- Непосредственное исследование поставленной перед DS в проекте проблемы влияния различных факторов/параметров на качество контроля классификации услуг медицинских организаций и выставляемых ими счетов для оплаты со стороны ФСМС. Это исследование было реализовано

за счёт применения наиболее адекватных и эффективных моделей МО. Оценка эффективности моделей при помощи специальных и общепринятых в МО метрик.

- Формирование выводов по результатам предварительного анализа и выработка предложений по дальнейшей разработке Пилот-проекта.

***Пользователями системы являются:***

- Административные работники организации ФСМС
- Практические работники, занятые анализом и оценкой входных данных
- Специалисты ИТ и программисты
- Специалисты в области Data Science

***Стартовые условия: Информационное, техническое, программное и кадровое обеспечение этапа «Моделирование» Пилот-проекта***

1. Количество переменных, применяемых в анализе, составило 6, в том числе:

Зависимые переменные (переменные отклика) – это бинарные переменные:

- a. MONTHLY\_SERVICE\_EXCEEDS\_ONE
- b. WEEKLY\_SERVICE\_EXCEEDS\_ONE

Зависимые переменные принимает значения:

- 1 – если количество услуг превышает, пороговое значение за определенный период.
- 0 – если количество услуг находится в допустимых пределах.

Независимые переменные:

- c. REGION, GENDER, AGE, IS\_CITY, SERVICE\_PRICE

2. Среднее время работы над анализом каждой из в общей сложности 18 моделей (по 9 переменных отклика, варианты: а) и б)) для не превышало 1-го часа. Максимальное время работы составило более 3 часов, модель SVM работала более 10 часов и была прервана разработчиком).

3. В качестве примера:

- Тестовый пример простейшего анализа на примере Логистической регрессии большого объема данных (более 170 млн. записей из открытых источников в Интернете) потребовал один час работы Ноутбука.
- Сложный анализ при помощи GLLM был прерван после более чем 30-ти часов непрерывной работы Ноутбука.

Информационная компонента.

Для моделирования использовался набор данных, состоящий из 300.000 строк и 9 столбцов, размер матрицы для анализа составляет 8.6 МБ

|                                                                                                    |                                   |          |
|----------------------------------------------------------------------------------------------------|-----------------------------------|----------|
|  df_scaling.csv | Comma Separated Values-Quelldatei | 8.638 KB |
|----------------------------------------------------------------------------------------------------|-----------------------------------|----------|

Техническая составляющая. Моделирование осуществлялось на Ноутбуке с техническими характеристиками:

Имя устройства Lenovo

Процессор Intel(R) Core(TM) Ultra 9 185H 2.30 GHz

Оперативная память 64,0 ГБ (доступно: 63,6 ГБ)

Тип системы 64-разрядная операционная система, процессор x64

Дата установки 28.07.2024

Программная характеристика. Разработка осуществлялась среде Windows-11, языками программирования являлись: Python v13.3, R-Studio.

## Функциональная характеристика

### 1. Целевые переменные:

- WEEKLY\_SERVICE\_EXCEEDS\_ONE: Превышение одной услуги в неделю.
- MONTHLY\_SERVICE\_EXCEEDS\_ONE: Превышение одной услуги в месяц.

### 2. Независимые переменные:

- Пол (GENDER), возраст (AGE), регион (REGION), тип населённого пункта (IS\_CITY), список услуг (SERVICE\_LIST), стоимость услуг (SERVICE\_PRICE) и др.

### 1. Количество переменных, применяемых в анализе, составляло 6, в том числе:

Зависимые переменные (переменные отклика):

- а. MONTHLY\_SERVICE\_EXCEEDS\_ONE со значениями 0,1
- б. WEEKLY\_SERVICE\_EXCEEDS\_ONE со значениями 0,1

Где:

0 – нормальный случай

1 – случай с отклонениями от нормы

Независимые переменные:

- с. REGION, GENDER, AGE, IS\_CITY, SERVICE\_PRICE

Кадровое обеспечение. Работа выполнена самостоятельно внешним специалистом в области Вычислительной Математики, Методов оптимизации, Биостатистики и Data Science. На данную стадию проекта было затрачено в целом 230 рабочих часов (декабрь 2024г.).

## ***Организационно-функциональная схема работы «ИИ ФСМС» на первом и вторых уровнях организации***

«ИИ ФСМС» является функционально целостной и территориально распределенной как информационно так и в отношении эксплуатации системой. Для обеспечения функциональной и программно-технической целостности и идентичности принято решение:

1. Осуществлять моделирование в Вычислительном Центре Центрально Аппарате ФСМС
2. Осуществлять своевременную передачу полученных моделей в территориальные организации
3. Осуществлять регулярный мониторинг работы моделей и анализ результатов в территориальных организациях

Такая технологическая схема позволяет:

1. Централизовать разработку, сопровождение и техническое обслуживание системы в Головном Центре
2. Освободить сотрудников нижестоящих уровней ФСМС от несвойственной им работе по созданию и сопровождению ИИ
3. Значительно сократить затрат временных и трудовых ресурсов на созданию и сопровождению ИИ

## Схема работы «ИИ ФСМС» на первом и вторых уровнях




Рис. 20. Схема работы «ИИ ФСМС» на первом и вторых уровнях организации

### Моделирование (Monthly data)

На стадии предварительного анализа МО была исследована проблема классификации переменных отклика

1. MONTHLY\_SERVICE\_EXCEEDS\_ONE
2. WEEKLY\_SERVICE\_EXCEEDS\_ONE

в наборе предоставленных данных с помощью различных моделей.

Моделирование осуществлялось при помощи методов и средств машинного обучения в среде программирования Python. Для исследования проблемы были выбраны идентичные 9 моделей для каждой целевой переменной (Месячной и недельной, в сумме 18 моделей), в том числе:

- Random Forest
- Decision Tree1
- XGB\_grid\_model
- XGB
- GradientBoosting (a)
- GradientBoosting (GBd)
- DecisionTree2
- KNeighbors
- Ada Boost (Parameter Grid)

В результате работы каждой модели выдаются следующая информация в форме таблиц и графиков:

- Таблица классификация
- Матрица несоответствий
- ROC график
- Дополнительные графики (4 на одной панели)
- Precision-Recall график

Таблица классификация даёт оценку модели по критериям:

- *accuracy*
- *precision*
- *recall*
- *f1-score*

Графики дают оценку модели по критериям:

- *Распределении откликов 0,1 по критерию True-False*
- *auc*
- *ROC*
- *Сотношении Precision-Recall*

Результаты моделирования в виде графиков, отчетов классификации, метрик и другая информация сохранялись в форме csv-File, Image, Map.

В данном документе приведена выходная информация для переменной отклика MONTHLY SERVICE EXCEEDS ONE.

### **Выходные результаты работы системы**

В качестве примера выходных результатов приводятся выходные данные для модели Random Forest, остальные модели выдают по результатам работы аналогичные по форме результаты.

### **Модель 1: Random Forest. Результаты работы в виде таблиц и графиков**

Таб. 1. Таблица классификации №1

| <i>Classes+Met</i>                                   | <i>prec</i> | <i>reca</i> | <i>f1-</i> | <i>sup</i> | <i>AUC</i> |
|------------------------------------------------------|-------------|-------------|------------|------------|------------|
| class 0                                              | 0.94        | 0.97        | 0.96       | 552        | 0.679      |
| class 1                                              | 0.56        | 0.38        | 0.45       | 479        | 0.679      |
| accuracy                                             | 0.92        | 0.92        | 0.92       | 0.92       | 0.679      |
| macro avg                                            | 0.75        | 0.67        | 0.70       | 600        | 0.679      |
| weighted avg                                         | 0.91        | 0.92        | 0.92       | 600        | 0.679      |
| © Dr. Alexander Wagner. Все права охраняются законом |             |             |            |            |            |

### **Пояснение к отчету о классификации**

Отчет о классификации — это отчет об оценке производительности, который используется для оценки производительности моделей машинного обучения по следующим 5 критериям:

- Точность (Accuracy) — это показатель, используемый для оценки производительности модели. Чем он выше, тем лучше (в таблице не указана, приведена ниже матрицы путаницу).
- Полнота (Recall) измеряет способность модели правильно предсказывать истинные положительные значения.

- Точность (Precision) — это отношение числа истинно положительных результатов к сумме числа истинных и ложных положительных результатов.
- F-score объединяет точность и полноту в одну метрику. В идеале ее значение должно быть ближе к 1, тем лучше.
- Поддержка (Support)— это количество фактических появлений каждого класса в наборе данных.




Рис. 21. Матрица несоответствий

### ***Матрица несоответствий (Confusion Matrix), инструмент производительности***

Матрица несоответствий дает хорошее базовое представление о том, как строить различные оценочные показатели.

Матрица несоответствий — это инструмент измерения производительности, часто используемый для задач классификации машинного обучения, где выход модели может быть 2 или более классов (т. е. бинарная классификация и многоклассовая классификация). Матрица несоответствий особенно полезна при измерении полноты, точности, специфичности, достоверности и AUC модели классификации.

Чтобы лучше концептуализировать матрицу путаницы, лучше всего понять интуицию ее использования для проблемы бинарной классификации. Матрица несоответствий выглядит следующим образом (см. Схема 1 выше пол тексту)




Рис. 22. ROC Curve

Кривая AUC-ROC не является предпочтительной при сильном дисбалансе, поскольку она дает слишком оптимистичные результаты, особенно если число редких классов очень мало, как в нашем случае. Обычно для сценариев Imbalanced предпочитают PR-AUC в качестве метрики выбора (см. Precision-Recall график ниже).

Кривая точности-полноты (Precision-Recall) отображает компромисс между точностью (Precision) и полнотой (Recall) для разных порогов. Большая площадь под кривой представляет как высокую полноту, так и высокую точность, где высокая точность связана с низким уровнем ложноположительных результатов, а высокая полнота связана с низким уровнем ложно-отрицательных результатов.

Высокие баллы для обоих вариантов показывают, что классификатор возвращает точные результаты (высокая точность), а также возвращает большинство всех положительных результатов (высокая полнота). Кривая PR основана на вероятностях и не является пороговой метрикой.




Рис. 23. Precision-Recall график

### Оценка моделей

В результате моделирования нами получена оценка выходные данные и характеристики 9-ти моделей машинного обучения. Результаты представлены в виде таблиц и графиков.

Обобщенная таблица 17 и объединенный график ROC на график 71 показывают сравнительные характеристики моделей. График 72 служит для оценки PR-характеристики для всех моделей.

На графике 73 даётся Сравнение 9-ти моделей (по Тест-данным) по метрикам: Accuracy, Precision, Recall, AUC.




Рис. 24. Представление ROC-кривой для всех моделей на одной панели




Рис. 25. Представление PR-кривой для всех моделей на одной панели

**Таб. 2. Характеристика всех моделей после расчёта с использованием тестового набора данных**

| <i>Model</i>                                         | <i>Accuracy</i> |
|------------------------------------------------------|-----------------|
| XGB                                                  | 0.9362          |
| XGB_grid_model                                       | 0.9358          |
| GradientBoosting (GBd)                               | 0.9329          |
| GradientBoosting (a)                                 | 0.9288          |
| Random Forest                                        | 0.9273          |
| Ada Boost(Parameter                                  | 0.9270          |
| KNeighbors                                           | 0.9264          |
| DecisionTree2                                        | 0.9259          |
| Decision Tree1                                       | 0.9059          |
| © Dr. Alexander Wagner. Все права охраняются законом |                 |

**Таб. 3. Характеристика всех моделей после расчёта с использованием тестового набора данных**

| <i>Model</i>                                         | <i>Accuracy</i> | <i>Precision</i> | <i>Recall</i> | <i>F1</i> | <i>AUC</i> |
|------------------------------------------------------|-----------------|------------------|---------------|-----------|------------|
| XGB                                                  | 0.9362          | 0.7018           | 0.3496        | 0.4667    | 0.8724     |
| XGB_grid_model                                       | 0.9358          | 0.6902           | 0.3569        | 0.4705    | 0.8738     |
| GradientBoosting (GBd)                               | 0.9329          | 0.6654           | 0.3219        | 0.4339    | 0.8576     |
| GradientBoosting (a)                                 | 0.9288          | 0.7016           | 0.1888        | 0.2975    | 0.8249     |
| Random Forest                                        | 0.9273          | 0.5666           | 0.3834        | 0.4573    | 0.8362     |
| Ada Boost(Parameter Grid)                            | 0.9270          | 0.6795           | 0.1623        | 0.2620    | 0.8373     |
| KNeighbors                                           | 0.9264          | 0.5852           | 0.2708        | 0.3702    | 0.7843     |
| DecisionTree2                                        | 0.9259          | 0.5956           | 0.2261        | 0.3278    | 0.8188     |
| Decision Tree1                                       | 0.9059          | 0.4107           | 0.4095        | 0.4101    | 0.6792     |
| © Dr. Alexander Wagner. Все права охраняются законом |                 |                  |               |           |            |




Рис. 26. Сравнение 9-ти моделей (Тест-данные) по метрикам: Accuracy, Precision, Recall, AUC

На приведенном Рис. 24 для ROC-кривых имеют место следующие моменты:

Различные кривые ROC на нём – Различные модели: существуют различные кривые (красные, зеленые, оранжевые, синие и т. д.), относящиеся к различным моделям. Эти модели могут отличаться из-за того, что их можно обучать с использованием различных гиперпараметров. Параметр AUC для каждой модели приведен в Таблице 18.

Диагональная линия – Случайное угадывание: пунктирная красная линия, проходящая из нижнего левого угла в верхний правый, указывает на то, что модель дает верный ответ только в 50% случаев, что не лучше угадывания для бинарного классификатора.

Лучшие модели: модель с кривой ROC выше красной пунктирной линии можно считать лучшей, чем случайное угадывание, и ее можно рассматривать для принятия. Чем больше кривая изгибается к верхнему левому углу, тем точнее модель.

Худшие модели: модель с ROC-кривой ниже красной пунктирной линии можно считать худшей, чем случайное угадывание, и ее следует отвергнуть.

Точки на ROC-кривой: Точки на каждой ROC-кривой представляют пороги принятия решений и соответствующие значения истинно положительного и ложноположительного коэффициентов. Различные пороги приводят к различным значениям TPR и FPR и, соответственно, к различной общей производительности модели.

Идеальный порог принятия решения: порог принятия решения может быть таким, который приводит к очень высокому значению TPR (близкому к 1) и очень низкому значению FPR (близкому к 0).

AUROC представляет площадь под ROC-кривой (AUROC). Площадь под ROC-кривой вычисляется для характеристики производительности модели классификации. Площадь под кривой (AUC или ROC AUC) используется в качестве общей меры точности. Чем выше AUC или AUROC, тем лучше модель предсказывает нули как нули и единицы как единицы. В нашем случае лучшей моделью является **XGB\_grid\_model**.

### Прогноз отклика Monthly рассчитанный моделями Машинного Обучения

Таб. 4. Прогнозные значения переменной отклика Monthly рассчитанные 8 моделями Машинного Обучения

| Пилот-проект: Разработка Системы Искусственного Интеллекта для ФСМС                     |     |         |       |       |                              |        |               |               |                |                |                       |                    |           |               |
|-----------------------------------------------------------------------------------------|-----|---------|-------|-------|------------------------------|--------|---------------|---------------|----------------|----------------|-----------------------|--------------------|-----------|---------------|
| Прогнозные значения переменной отклика Monthly рассчитанные моделями Машинного Обучения |     |         |       |       |                              |        |               |               |                |                |                       |                    |           |               |
| Region                                                                                  | Age | Gender  | Price | Sity  | Service                      | Actual | Random Forest | Decision Tree | XGBoosting (d) | XGBoosting (a) | Gradient Boosting (a) | Decision Tree (GB) | KNeighbor | AdaBoost Grid |
| 0                                                                                       | 11  | мужской | 397   | Город | Диагностические исследования | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 11                                                                                      | 23  | мужской | 279   | Город | Диагностические исследования | 0      | 0             | 1             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 18                                                                                      | 53  | женский | 268   | Город | Диагностические исследования | 0      | 1             | 1             | 1              | 1              | 0                     | 1                  | 1         | 0             |
| 18                                                                                      | 44  | женский | 191   | Город | Диагностические исследования | 0      | 0             | 0             | 0              | 1              | 1                     | 0                  | 0         | 1             |
| 18                                                                                      | 28  | женский | 268   | Город | Диагностические исследования | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 18                                                                                      | 35  | мужской | 513   | Город | Консультативный прием        | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 18                                                                                      | 46  | мужской | 268   | Город | Диагностические исследования | 0      | 1             | 1             | 1              | 1              | 1                     | 0                  | 1         | 0             |
| 18                                                                                      | 77  | женский | 268   | Город | Диагностические исследования | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 18                                                                                      | 46  | мужской | 150   | Город | Диагностические исследования | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 18                                                                                      | 25  | мужской | 513   | Город | Консультативный прием        | 0      | 0             | 0             | 1              | 1              | 1                     | 0                  | 0         | 1             |
| 11                                                                                      | 34  | женский | 513   | Город | Консультативный прием        | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 18                                                                                      | 23  | мужской | 268   | Город | Диагностические исследования | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 18                                                                                      | 24  | мужской | 268   | Город | Диагностические исследования | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 18                                                                                      | 60  | женский | 513   | Город | Консультативный прием        | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 11                                                                                      | 45  | мужской | 513   | Город | Консультативный прием        | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 18                                                                                      | 60  | женский | 268   | Город | Диагностические исследования | 0      | 1             | 0             | 1              | 1              | 1                     | 0                  | 1         | 1             |
| 18                                                                                      | 42  | мужской | 268   | Город | Диагностические исследования | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 18                                                                                      | 10  | женский | 191   | Город | Диагностические исследования | 0      | 1             | 0             | 1              | 1              | 1                     | 0                  | 1         | 1             |
| 18                                                                                      | 84  | женский | 513   | Город | Консультативный прием        | 0      | 1             | 0             | 0              | 1              | 1                     | 0                  | 1         | 1             |
| 18                                                                                      | 24  | женский | 268   | Город | Диагностические исследования | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 18                                                                                      | 7   | мужской | 191   | Город | Диагностические исследования | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 18                                                                                      | 63  | мужской | 268   | Город | Диагностические исследования | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 18                                                                                      | 42  | мужской | 235   | Город | Диагностические исследования | 0      | 1             | 1             | 1              | 1              | 1                     | 1                  | 1         | 0             |
| 18                                                                                      | 80  | женский | 101   | Город | Диагностические исследования | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 18                                                                                      | 73  | женский | 513   | Город | Консультативный прием        | 0      | 1             | 1             | 1              | 1              | 1                     | 1                  | 1         | 0             |
| 18                                                                                      | 39  | мужской | 513   | Город | Консультативный прием        | 1      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |
| 18                                                                                      | 92  | мужской | 191   | Город | Диагностические исследования | 0      | 0             | 0             | 0              | 0              | 0                     | 0                  | 0         | 0             |

### Краткое описание программного обеспечения «ИИ-ФСМС»

В данном подразделе приводится описание Эко-системы «ИИ-ФСМС» и режима её работы. Для разработки Эко-системы «ИИ-ФСМС» нами использовалась библиотека Python (a) Streamlit.

### Выводы

На основании полученных результатов моделирования были сделаны следующие выводы:

1. Качество и информативность данных «ИИ-ФСМС», предложенных для моделирования, оказалось не очень высоким. Это означает, что требуются дополнительные независимые переменные, возможно сконструированные из имеющихся. Примером может служить параметр, сконструированный из роста и массы тела человека по формуле Кетле, так называемый BMI (Body mass index) или показатель Кетле.
2. Имеется большая несбалансированность данных: выше 93% для отклика 0 и менее 8% для отклика 1 и это затрудняет получение достоверных прогнозов, которые производят модели
3. Ноутбук оказался достаточно эффективным для сложных вычислений объемов данных в размере до 300 тысяч записей и для данных моделей.
4. Тестирование более сложных моделей показало, что Ноутбук имеющий CPU Processor, ограничен в своих вычислительных возможностях и требуется для реализации сложных моделей GPU Processor или размещение «ИИ-ФСМС» на

Web-платформе и моделирование в режиме Cloud-Computing с большими вычислительными мощностями.

***Предложения для оптимизации дальнейшей разработки «ИИ-ФСМС»***

*Исходя из приобретенного опыта и для оптимизации процесса разработки и внедрения «ИИ-ФСМС» предлагается следующее:*

1. Необходимо провести дополнительную чистку входных данных (Data Cleaning)
2. Провести расширенный и углублённый разведочный анализ данных (EDA) и на его результатах попытаться сконструировать новые независимые переменные
3. Для устранения проблемы несбалансированности данных требуются новые технологии и методы (Bootstrapping, Surveyselect, Monte-Carlo Simulation, Bayesian statistics and modelling и др.) и, соответственно, Software реализующие эти методы



PUBLIC HEALTH

OBSERVATIONAL RESEARCH

MACHINE LEARNING-BASED DETECTION OF MEDICAL SERVICE  
ANOMALIES: KAZAKHSTAN'S HEALTH INSURANCE DATA

Maksut Kulzhanov<sup>1</sup>, Alexander Wagner<sup>1</sup>, Abylkair Skakov<sup>2</sup>,

Ilyas Mukhamejan<sup>2,1</sup>, Saya Zhorabek<sup>1</sup>, Ainur B. Qumar<sup>1</sup>

<sup>1</sup> Department of Health Policy and Management, Asfendiyarov Kazakh National Medical University, Almaty, Kazakhstan

<sup>2</sup> JSC "Social Health Insurance Fund", Almaty, Kazakhstan

Received: May 3, 2025

Accepted: June 18, 2025

Abstract

**Background.** With the exponential growth of medical data and limited analytical resources, healthcare systems are increasingly adopting Artificial Intelligence (AI) and Machine Learning (ML) technologies to enhance their decision-making processes.

This research aims to apply advanced ML algorithms to analyze data from the Republic of Kazakhstan's Obligatory Health Insurance Fund (OHIF) and automatically detect anomalies in the structure of delivered medical services.

**Methods.** An automated AI system was developed and tested using nine ML models, including XGBoost, Random Forest, Decision Tree, Gradient Boosting, etc. The dataset comprised 329,584 real records, including demographic and socio-economic parameters. Model performance was evaluated using accuracy, precision, recall, F1-score, and the area under the curve (AUC). ROC and PR curves were used for visual validation.

**Results.** Among the tested models, XGBoost and XGB\_grid\_model achieved the highest performance, with an accuracy of 93.2% and 93.6%, respectively. Precision: 91.8% and 92.1%, Recall: 90.4% and 91.3%, F1-score: 91.1% and 91.7%, AUC: 0.874 and 0.882. These models reliably detected irregularities such as billing duplications, out-of-pattern service provision, and inconsistencies with demographic profiles.

**Conclusion.** The results demonstrate the feasibility of using ML for automated medical billing control. This approach can significantly enhance the transparency, accuracy, and accountability of healthcare financing in Kazakhstan, laying the groundwork for broader AI integration in national health systems.

**Keywords:** artificial intelligence, machine learning, data science, health insurance, predictive modeling, healthcare analytics, Kazakhstan.

**How to cite:** Kulzhanov M, Wagner A, Skakov A, Mukhamejan I, Zhorabek S, Qumar A. Machine learning-based detection of medical service anomalies: kazakhstan's health insurance data. Cent Asian J Med Hypotheses Ethics 2025;6(2):133-141. <https://doi.org/10.47316/cajmh.e.2025.6.2.07>

Introduction

The modern healthcare system faces increasing volumes of medical information, the need for prompt quality control and appropriateness of medical services, as well as limited resources for checking and analyzing large amounts of data. In these conditions, Artificial Intelligence (AI) and Machine Learning (ML) technologies are becoming powerful tools for enhancing the efficiency and reliability of decisions, particularly in health insurance systems. Data science, as an applied discipline, utilizes machine learning methods to extract meaningful patterns and insights from large volumes of data [1]. For data analytics specialists, a deep understanding

of machine learning algorithms is critical to solving complex analytical problems. Knowledge and practical application of these methods can significantly enhance the efficiency of analytical work and yield higher-quality results in data-driven projects [2].

However, despite the high potential of Data Science, mastering its technical and scientific tools — especially statistical methods and computing systems — requires significant time and intellectual resources [3]. This is becoming a serious challenge for many organizations, especially in the healthcare sector, where there is an acute shortage of qualified specialists in statistics and data analysis [4].

**Corresponding author:** Ainur B. Qumar, PhD, Professor of the Health Policy and Management Department, Asfendiyarov Kazakh National Medical University, Almaty, Kazakhstan  
E-mail: [a.kumar@kaznmu.kz](mailto:a.kumar@kaznmu.kz) X handle: @ainurabk

## **Глава 11. Выводы на основании опыта разработки WEB-базируемых систем Искусственного Интеллекта в Здравоохранении и перспективы дальнейшего развития Системы Искусственного Интеллекта «HealthAI»**

### **Выводы на основании опыта разработки WEB базированных систем Искусственного Интеллекта в Здравоохранении**

В данной монографии изложены основы создания аналитических информационных систем в здравоохранении с помощью методов продвинутой статистики(Advanced statistics), Искусственного Интеллекта и Web-технологий. Шесть глав были посвящены теоретическим вопросам, методическим и практическим рекомендациям СИИ, в том числе:

- Истории развития ИИ
- Базовым теоретическим положениям ИИ
- Основным понятиям работы в WEB пространстве с системами Искусственного Интеллекта
- Основам программирования в среде Anaconda, Python, Jupyter Notebook

В четырёх главах были детально описаны системы, посвященные конкретным темам из практики, в том числе

- АИС ВТИ
- АСНИ-МЕД
- АИС Обучение
- ИИ ФСМС

Эти системы различаются по назначению, уровню сложности и трудовым затратам на их разработку. Для создания этих систем использовались передовые технологии проектирования и эксплуатации на Cloud Platform(ax). По результатам разработки и эксплуатации этих систем можно сделать следующие выводы:

- Разработка **Веб ИИ** – это задача повышенной сложности, требующая от разработчика большого спектра знаний из различных областей науки и техники, таких как:
  - Математика
  - Статистика
  - Оптимизация
  - Программирование
- Высокая трудоемкость работ по разработке таких систем
- Строгие требования к техническому обеспечению этих систем
- Строгие требования к качеству входных данных
- Высокие требования к творческим способностям разработчика

Все эти вопросы многократно обсуждались в профессиональной прессе, на Web-форумах и других площадках. Резюмируя вышесказанное можно утверждать, что создание систем Искусственного Интеллекта – это профессия будущего и требуется приложить немалые усилия для создания условий привлечения талантов в эту область деятельности. Создать им условия для приобретения специальных знаний и выработки навыков для создания систем такого класса. Это потребует, прежде всего, повышение роли математики и обучение точным наукам в школах, начиная с младших классов. Советская школа математики была сильнейшей в мире, к сожалению за последние десятилетия эти позиции были утрачены во всех постсоветских независимых государствах. Потребуются большие усилия для возвращения к прежнему уровню.

Авторы показали на конкретных примерах как создаются такие аналитические системы. Разработчиками предложена эко-системы «WEB ИИ» как многоядерная, распределенная, WEB-базируемая среда (обитания) в пространстве **«Разработчик приложений-WEB Платформа-Пользователь приложений»** или в общепринятых терминах **«App developer -WEB Platform-App User»**. Эко-системы «WEB ИИ» для эксплуатации WEB базированных систем Искусственного Интеллекта предназначена для стандартизации и оптимизации процесса эксплуатации.

Это позволяет:

- Унифицировать процесс создания WEB-базированных систем Искусственного Интеллекта
- Сократить затраты на рутинные операции по переносу данных с локального компьютера на Cloud-Server и обратно
- Избежать потерь данных
- Обеспечить регулярное обновление систем и поддержание их в актуальном состоянии

### **Перспективы дальнейшего развития Эко-Системы Искусственного Интеллекта «HealthAI»**

- Определение главного конструктора СИС из руководства 1-го уровня
- Определение финансирования работ по созданию и развитию СИС
- Создание минимально-достаточного по численности коллектива квалифицированных разработчиков СИС
- Определение стратегии и разработка плана долгосрочного и краткосрочного развития СИС
- Разработка Технического задания на создание СИС
- Проведение мероприятий по администрированию и кадровому обеспечению СИС
- Проведение мероприятий по техническому и программному обеспечению СИС
- Проведение мероприятий по опытной эксплуатации и внедрению СИС
- Проведение мероприятий по организации процесса обучения студентов и сотрудников Уни освоению и работе с СИС
- Организация сотрудничества с подразделениями Минздрава Казахстана по кооперации работ и использованию СИС в том числе и на коммерческой основе